

人工神经网络与 SSO 算法相结合的新型灵活网格交易模型

叶伟昌^{1,*}、谢裕欣¹、黄嘉玲²

¹ 清华大学工业工程与工程管理系

新竹 300044, 台湾; 叶伟昌: yeh@ieee.org; 谢永宏: kypss93003@gmail.com

² 台湾高雄大学国际物流与运输管理系, 高雄市33857; clhuang@mail.knu.edu.tw

* 通讯地址: yeh@ieee.org

摘要: 随着网络和计算机技术的不断发展, 金融市场交易方式和策略已从传统的现场交易逐步转变为电子远程交易, 甚至由预设程序执行的在线自动交易。量化交易作为将投资者的决策自动转化为固定且可量化的操作逻辑, 消除了所有情绪干扰和主观思维的影响, 并将这种逻辑应用于金融市场活动以获取高于平均收益的超额利润, 这一方法在金融市场上引起了广泛关注。开发金融市场自动交易的自适应编程算法已成为学术研究与金融实践的首要课题。为此, 本研究开发并研究了一种新型灵活网格交易模型: 该模型结合简化群体优化 (SSO) 算法 (用于根据市场输入值优化参数), 以及全连接神经网络 (FNN) 与长短期记忆 (LSTM) 模型 (用于训练量化交易模型, 通过输入市场数据自动计算并调整最优交易参数)。该模型通过自适应机制降低投资者交易负担, 不仅获得超越市场的投资回报率和模型稳健性, 还能有效平衡风险与收益。

关键词: 灵活网格交易模型、简化群优化 (SSO)、人工智能 (AI)、全连接神经网络 (FNN)、长短期记忆 (LSTM) 模型。

1. 介绍

自20世纪末至今, 随着网络与计算机技术的持续发展, 金融市场交易方法与策略的制定方式已发生根本性变革。越来越多的金融机构和主要市场交易正逐步从传统的现场交易转向电子远程交易, 甚至可以通过预编程计算机程序 (算法交易) 实现自动化交易。据统计, 目前金融发展最成熟的美国股市, 其交易量占比高达60%至70%。

在计算机计算技术与金融市场的应用浪潮中，量化交易与计算机算法的结合尤为繁荣[1]。

金融市场的核心功能在于提供交易商品的实时市场价格，使市场参与者能够从中获益。量化交易技术于20世纪末在股票市场兴起，近年来已广泛应用于股票、外汇及期货市场的自动化交易系统。为获取超额收益，该技术通过运用统计学与数学模型，分析历史数据以预测未来市场走势的概率分布，进而建立相应的量化交易逻辑体系。

量化交易的最大特点是采用一套固定的交易逻辑，这种逻辑最常应用于股票和期货交易市场，旨在获得稳定且持续高于平均回报的超额收益。此外，量化交易所考量的维度正日益多元化，包括市场构成、投资标的的发展评估、市场情绪等要素，这些均可用于深入分析和参考。随着信息时代的演进，海量相关数据已被完整采集并留存，这不仅为量化交易模型提供了分析参考，更弥补了人类大脑难以快速处理海量数据的局限，使决策过程更加客观，不受市场情绪干扰。

当今时代，随着时代变迁，国际贸易与互联网的蓬勃发展推动了自由贸易市场的活跃发展，这不仅降低了交易成本，还拓展了交易规模与范围。与此同时，金融业与技术的深度融合也日益成熟并广受欢迎[2,3]。如何将日益发达的计算机技术作为金融市场交易的辅助工具，甚至成为交易者获利的关键，已成为近年来金融界研究的焦点。

在电子商务应用的早期阶段，人们主要关注如何将传统的实体交易形式转变为电子交易形式，包括以电子文件形式输入和存储交易信息，以便于未来的检索和分析。这种简单的交易方式从手工服务转变为电子服务，极大地降低了人力成本。

近年来电子金融领域取得初步成果后，金融从业者不仅希望借助计算机完成简单交易流程，更期待运用成熟的计算机程序辅助人们做出更复杂的交易决策。尤其在人工智能领域，近年来发展势头愈发强劲，已取得多项突破性进展[4-7]。如何运用计算机程序模拟人类思维逻辑、辅助交易决策，甚至实现比人类更快、更广、更深的思考，已成为近年来金融领域研究与发展核心方向。

自20世纪80年代末以来，交易相关编程算法已逐渐兴起。早期阶段，分析与决策主要依赖人工或统计工具，而交易则由计算机程序完成。但过去十年至二十年间，量化交易已逐渐成为主流模式。

决策过程被设计成交易算法，其交易逻辑使得算法更加智能化和自动化。这一研究已成为高度实用且广受欢迎的领域，吸引了众多政府和金融机构的关注与实践[8]。

当前，交易算法研究领域已涌现出诸多丰富多样的研究成果。例如：运用均值回归调整股票投资权重分配[9]；结合长短期记忆（LSTM）与网格交易法（GTM）预测外汇交易市场趋势[10]；采用箱线理论与支持向量机（SVM）辅助股票交易决策[11]；运用一目均衡表分析外汇交易[12]；以及采用市场趋势而非固定时间序列来制定执行单元的交易策略[13]。不难看出，借助计算机程序辅助交易乃至直接做出交易决策并执行交易，已成为金融发展不可阻挡的趋势。

网格交易法最基础的定义是：在特定价格区间内设置平均挂单，以执行低买高卖的交易策略[14]。其原理虽简单，却能在价格波动时有效赚取点差收益。近年来，该策略已被广泛应用于多个金融市场的套利交易[15-16]。

简化群优化（SSO）由叶[17]于2009年提出，旨在通过简化核心理念改进粒子群优化（PSO）在解决离散问题时的局限性。SSO通过简化算法并提升求解效率，已在多个领域得到广泛应用[18-29]。寻找最佳参数组合是其主要SSO应用之一。该方法可同时考虑并调整多个参数以确定最优组合，已成功应用于卷积神经网络超参数组合优化[30]、太阳模型参数优化[31-33]以及人工神经网络（ANN）参数调整[34]。

近年来，深度学习（DL）与人工神经网络（ANN）在金融领域的应用日益广泛，其中最具代表性的应用是股票市场、汇率及金融指数的预测等[35]。目前，仍有许多研究尝试运用各类神经网络模型，以辅助金融预测与决策[36-38]，从而实现更理性、更精准的判断。

总之，本研究提出了一种新型网格交易模型，采用SSO算法将适用于不同市场环境的参数作为输入值和标签，训练全连接神经网络和LSTM模型，最终通过输入当前市场状况，定量交易模型可自动计算并调整最优交易参数。

随着电子商务和量化交易的兴起，人们的经济活动与技术的关系越来越紧密，许多交易都依赖于程序来完成。未来趋势中，相关程序不仅能协助用户记录交易并完成资金划转，更能实现交易决策自动化，包括自动确定交易时机与价格。基于上述背景，本研究旨在：

1. 提供一套新的网格交易算法以改善过早入场和过早离场的缺陷

当前市场中现有的网格交易模式。

2. 该交易算法能够适应外部环境的变化，随着时间和市场条件的变化，自动调整模型以减少投资者在交易市场中的努力。
3. 通过一套具有逻辑规则的交易模型，减少了投资者主观交易决策带来的非理性决策。
4. 平衡风险与收益的关系，在合理风险范围内获得丰厚回报。

2. 网格交易、SSO 和DL概述

2.1. 网格交易

网格交易法最基础的定义是：在特定价格区间内设置平均挂单，执行“低买高卖”的交易策略[14]。该策略的有效性取决于两个关键因素。首先是价格波动性，包括涨跌行情。若价格一路飙升，持有现货交易者能获得比网格交易更高的利润；若价格持续下跌，现货交易者基本无法获得太多盈利机会，而做空期货的买家则更容易获利。当市场呈现波动行情时，网格交易策略能带来最高收益。价格波动越剧烈，其收益率增幅就越大。由于多数市场存在剧烈价格波动且常呈现均值回归现象[39-41]，这种策略正被越来越多的市场参与者采用。

影响网格交易利润大小的另一个关键因素是参数设置，包括网格平均值、网格上限、网格下限、网格数量、初始价格、止损点、止盈点等。上述参数的设置应基于产品价格波动、交易成本、风险承受能力及本金金额等因素，这些因素直接影响网格交易的最终表现。

网格交易主要分为等距网和等比网两种，目前在实际中使用较多的是等距网。

等距网格的设置基于初始价格 P_0 ，网格上限 G_{ul} 、网格下限 G_{ll} 的设置，以及网格总数的确定。 n ，以及通过等式(1)计算网格间距 G_s 。

$$G_s = \frac{G_{ul} - G_{ll}}{n} \quad (1)$$

在网格模型设定后，交易即基于该网格进行金融产品的买卖，随价格涨跌而变化。关于等距网格的示例，请参见图1。




图1.等距网格交易示意图

等比例网格的网格间距 G_s 为固定比例，等比例网格按此比例计算。关于等比例网格的示例，请参见图2。




图2. 等比例网格交易示意图

2.2. 特殊感觉器官

简化群优化算法（Simplified Swarm Optimization，简称 SSO）由Yeh[17]于2009年提出，该算法基于个人最优解（ $pbest$ ）和全局最优解（ $gbest$ ）的概念，并引入随机数，使得解有机会跳出局部最优解，从而提高解的多样性。

SSO 与其他启发式算法的主要区别在于其特殊的更新机制。有三个特别重要的参数设置，包括 Cg 、 Cp 和 Cw ，其中 $Cg > Cp > Cw$ 。更新机制如等式(2)所示。根据随机数之间的对应关系

t

ρ 和 Cg 、 Cp 以及 Cw ，确定下一代解 $x_{i,j}$ ，该解可能是 $gbest$ 、 $pbest$ 、当前解或随机数。

$$x_{i,j}^{t+1} = \begin{cases} g_j, & \text{if } \rho \in [0, C_g) \\ p_{ij}, & \text{if } \rho \in [C_g, C_p) \\ x_{ij}^t, & \text{if } \rho \in [C_p, C_w) \\ x, & \text{if } \rho \in [C_w, 1) \end{cases} \quad (2)$$

$t \quad t \quad t \quad t$

其中，设 $x_{i,j} = x_{i,1}, x_{i,2}, \dots, x_{i,j}$ 为第 t 代中具有 j 个变量的第 i 个解； ρ 是服从 $[0,1]$ 区间均匀分布的随机数。

$t+1$

更新方法是：当 ρ 介于 $[0, Cg)$ 时，变量 $x_{i,j}$ 被当前所有解中表现最佳的全球最优解 gj 所替代；当 ρ 介于 $[Cg, Cp)$ 时，它被变量在历史迭代中最优的区域 pi, j 内解所替代；当介于 $[Cp, Cw)$ 时，保持前一代的解。

t

$x_{i,j}$ ；当 x 位于 $[Cw, 1)$ 区间时，将被替换为 x ，该随机数生成于变量的上下限范围内。此举旨在降低陷入局部最优解的概率，同时增加解的多样性。

2.3. 分升

本节概述了本研究采用的神经网络（ANN）、反向传播法以及长时记忆（LSTM）技术。

2.3.1. 人工神经网络

近年来，深度学习（DL）技术已广泛应用于医学、工业、交通等领域，能够有效支持语音识别和机器视觉的实现。作为一种基于人工神经网络（ANN）的机器学习（ML）算法，深度学习通过数据特征进行学习。

人工神经网络（ANN）的计算架构最初由WS.麦卡洛克和W.皮茨[42]提出，随后由众多杰出学者[43,44]不断改进，现已成为人工智能领域中著名的机器学习模型。

人工神经网络的基本结构分为输入层、隐藏层和输出层三部分，输入层的每个节点对应输入预测变量，输出层的每个节点对应目标变量，隐藏层夹在输入层和输出层之间。

除了输入层的节点外，人工神经网络（ANN）中的每个节点都与若干前级节点相连，因此该模型被称为全连接神经网络（FNN），且每个节点都具有相应的权重。

2.3.2. 反向传播法

在深度学习中，反向传播方法[45]是使模型完备的关键，常用于人工神经网络的训练与优化。通过反向传播，可高效求得损失函数对权重的梯度，进而采用梯度下降法[46]求解各权重。损失函数中的“损失”指的是实际值与预测值之间的误差。反向传播的核心思想是返回误差，使得权重能够利用误差大小进行梯度下降法，从而获得并更新更合适的权重，进一步减少误差并优化权重。

2.3.3. 激光扫描跟踪法

LSTM 是为提升循环神经网络（RNN）短期记忆能力而设计的模型，主要由记忆单元、输入门、输出门和遗忘门四个单元构成。

输入门控制本次数据是否输入存储单元，存储单元负责存储计算结果，遗忘门控制存储单元的清除，输出门控制运算结果的输出。

3. 建议方法

本研究提出的方法按顺序阐述如下：第3.1小节介绍网格交易的初始设置与运行机制；第3.2小节阐述柔性网格的概念及设置方法；第3.3小节展示如何运用SSO在不同场景下获取最优柔性网格参数。作为深度学习的训练基础，最终训练出的神经网络能够通过输入近期市场信息，自动输出适合交易的网格参数，从而从市场波动中获取超额收益，具体实现方式详见第3.4小节。

3.1. 网格交易运行机制

本节详细阐述本研究中网格交易的实践方法，包括初始参数设置与计算，以及后续的操作机制与流程。

3.1.1. 网格交易的初始参数设置

总共需要设定五个基本参数，即总投资资本 $F0$ 、初始价格

P_0 ，网络 G_{ul} 的上限，网络 G_{ll} 的下限，以及网络交易模型运行前的网络总数 n 。本研究将总投资资本和初始价格设定为控制变量，即在比较结果时，任何方法中使用的总投资资本和初始价格都将设定为相同的固定值，并在相同标准下进行比较。

在网络交易模型运行前，若网格为等间距网格，则需使用第2节中的等式(1)计算单位价格差 G_s （即网格间距）。 G_s 是等间距网格中的一个特定值。

距离网格。但它是等比例网格中的固定比例，例如，下一个网格的值是 $P_0 \cdot G_s = 110$ ，下一个网格是 $P_0 \cdot G_s^2 = 121$ 当 $P_0 = 100$ 且 $G_s = 1.1$ 时。该比率可通过下方等式 (3) 计算得出。

$$G_s = \sqrt[n]{\frac{G_{ul} - G_{ll}}{G_{ll}} + 1} \quad (3)$$

此外，还需计算在网络交易前用于购买现货的资金规模，即，初始购买现货 S_0 ，以便在价格上涨时卖出获利。以及在价格下跌时必须持有多少资金来购买现货，这里 C_0 表示开始持有现金。因此，总投资资金被分为两部分，如下等式所示。

(4)后续每个时期的持仓和资金分别用 S_j 和 C_j 表示，其中 j 代表第 j 个时期。

$$F_0 = S_0 + C_0 \quad (4)$$

为了计算现货 S_0 的初始购买量和现金 C_0 的初始持有量，首先需要计算上网格数 n_u 和下网格数 n_l ，两者的总和等同于如等式(5)所示的网格总数 n 。 n_u 和 n_l 的值可通过公式(6)-(7)分别获得。此处以等距网格为例进行说明。

$$n = n_u + n_l \quad (5)$$

$$n_u = (G_{ul} - P_0) / G_s \quad (6)$$

$$n_l = (P_0 - G_{ll}) / G_s \quad (7)$$

在计算上部网格数 n_u 和下部网格数 n_l 后，进一步利用方程。(8)-(9)计算现货初始买入量 S_0 和现金初始持有量 C_0 。此时，单细胞交易量 G_v 仍为未知值。

$$S_0 = G_v \cdot n_u \cdot P_0 \quad (8)$$

$$C_0 = G_v \cdot [(P_0 - G_s) + G_{ll}] / 2 \cdot n_l \quad (9)$$

最后，将公式(8)-(9)代入等式(4)以得到单细胞交易量 G_v ，该值可通过等式（10）计算得出。

$$G_v = F_0 / \{[(P_0 - G_s) + G_{ll}] / 2 \cdot n_l + n_u \cdot P_0\} \quad (10)$$

最后，使用等式（11）（等距网格）或等式（12）（等比例网格）计算每个网格单元 g_i 、 i 从1到 n 的价格。

$$g_i = G_{ll} + G_s \cdot (i - 1) \quad (11)$$

$$g_i = G_{ll} \cdot G_s^{(i-1)} \quad (12)$$

3.1.2. 网格交易运行机制

下图3（a）-（e）详细说明了网格交易模型在初始参数设定后如何根据市场价格进行更新和调整，以及如何在最后结算。

1. 当网格初始运行时，当前价格被用作基准，如图3（a）所示，将上述网格价格置于卖出订单上，将下一个网格价格置于买入订单上。



图3.网格交易操作图（a）

2. 若价格上升直至触及第一条网格线，则执行卖出操作，更新现货成交量及持仓资金，并在如图3（b）所示的原始网格位置下达买入订单。



图3. 网格交易操作图 (b)

3. 若价格回落至初始网格线，则执行买入操作，更新现货成交量及持仓资金，并在原始网格位置（如图3 (c) 所示）下达卖出订单。




图3. 网格交易操作图 (c)

4. 若价格持续下跌至网格线，则执行买入操作，更新现货成交量及持仓资金，并在图3所示的原始网格位置下达卖出订单 (d)。




图3.网格交易操作图（d）

5. 继续采用上述机制进行交易。尽管价格已回落至网格交易的原始点位，但已成功套利7倍，相当于7个网格的网格价差利润，如图3所示（e）。




图3.网格交易操作图（e）

6. 当网格交易模式即将关闭时，有2种方式可以结束，一是直接保留当前的现货和资金，二是以当前价格卖出现货并转换为现金，前者推荐在市场价格较低时使用，后者不推荐，本研究采用第二种方式关闭和结算网格。

有关网格交易操作的完整流程，请参阅下图4所示的网格交易操作流程。




图4. 网格交易操作流程。

3.2. 柔性网格的概念与体系结构

基于当前金融市场采用的等距等比例网格交易模型，本研究提出了一种新型自适应网格交易模型——灵活网格。该模型通过结合 SSO 算法与深度学习技术，构建了更具灵活性的网格结构，能够动态调整交易参数。

构建了适应市场变化和各种外部条件的体系。

在等距网格交易模型框架下，当市场波动时，该模型能发挥最大效益。即便价格回落至初始点位，仍可通过采用均值回归策略进行量化交易，从剧烈波动的市场中实现套利[47]。另一方面，等比率网格交易则能通过均值回归与均值跟踪策略的组合，在剧烈上涨行情中获得更优收益[48]。

本文提出的弹性网格同时兼顾了等距网格和等比率网格的优点，无论市场是横盘、上涨还是下跌，都能优于传统的网格交易结构。

当柔性网格初次设定时，还需设定其总投资资本 $F0$ 、初始价格 $P0$ 、网格上限 Gul 、网格下限 Gll 、上层网格数量 nu 以及下层网格数量 nl 。与其他模型相比，初始设置存在两个主要差异：

1. 等式(5)中的上网格数 nu 和下网格数 nl 不再通过等式(6)和等式(7)计算，而是可以预先设定。
2. 网格被划分为上下两部分，初始价格 $P0$ 作为边界。上部和下部可设置网格数量并拥有各自的网格间距比。上部网格间距比为 Gsu ，下部网格间距比为 Gsl 。需注意 Gsu 必须是大于0且小于1的数值， Gsl 必须是大于1的数值。其特点是随着价格升高，上部网格间距逐渐变小，即交易频率越来越高；同样，当价格较低时，下部网格间距会变得更小且更密集。

关于网格值的具体计算方法，请参阅公式（13）-（14），上部结构可参考下图5。

$$G_{su} = \frac{1}{\sqrt[n_u]{\frac{G_{ul} - P_0}{P_0} + 1}} \quad (13)$$

$$G_{sl} = \sqrt[n_l]{\frac{P_0 - G_{ll}}{G_{ll}} + 1} \quad (14)$$




图5. 柔性网格交易示意图。

灵活网格设计的核心理念在于：当价格处于高位时增加卖出频率，当价格处于低位时增加买入频次。该模型的中段结构与等距网格相似，下半部分更接近等比例网格，而上半部分则突破了现有等距网格和等比例网格的常规模式——在价格高位时采用更高密度的网格配置。该模型旨在整合等距网格与等比例网格的优势，无论市场呈现剧烈波动、持续上涨还是持续下跌，其表现均优于现有模型。

然而，要充分发挥灵活网格模型架构的优势，最佳参数设置和与市场情况相适应的自适应调整是决定模型成败的关键因素。为此，本研究采用 SSO 算法确定第3.3节所述不同场景下的灵活网格参数，并将计算得出的参数组合与对应市场情况输入第3.4节所述的人工神经网络（ANN）进行模型训练。最终，该研究构建的深度学习模型仅需输入当前市场情况，即可自动调整最适合当前市场环境的网格参数。

3.3. SSO 最优参数

本小节采用 SSO 算法对柔性网格的最优解进行调整

在前一节构建的柔性网格基础上，根据不同的市场条件，将市场状况和最优参数作为训练集输入人工神经网络（ANN），用于第3.4节的模型训练。

3.3.1. 目标与约束

本研究的主要目标是实现投资回报最大化。因此，市场投资商品价格由 SSO 算法在j周期更新后设定。目标模型请参考以下等式（15）。

$$\text{Max } S_j \times P_j \times C_j \quad (15)$$

其中 S_j 、 P_j 和 C_j 分别代表现货数量、商品市场价格以及初始购买现货 $S0$ 和初始持有资金 $C0$ 后最后一期持有的资金，这些参数通过总j期的价格输入。

此外，在灵活网格模型中，必须确保每笔交易的利润大于交易成本 $h\%$ （通常为交易费率），从而设定以下约束等式（16），其中 i 从0到 n 。

$$s.t. \quad g_{i+1} - g_i > h\% \times g_{i+1} \quad (16)$$

计算 g_i 可以参考公式（11）-（12）。代入后可以发现，该约束实际上是对网格参数 Gul 、 Gll 、 nu 和 nl 的约束。

另一方面，实验1和实验2对网格上下边界 Gul 、 Gll 、 nu 和 nl 施加了额外约束，如公式（17）-（19）所示，其中 x 的取值范围为0到j。

$$s.t. \text{（实验1）} P0 \times 105\% < Gul < P0 \times 130\% \quad (17)$$

$$P0 \times 70\% < Gll < P0 \times 95\% \quad (18)$$

$$s.t. \text{（实验2）} P0 \times 105\% < Gul < P0 \times 150\% \quad (17)$$

$$P0 \times 50\% < Gll < P0 \times 95\% \quad (18)$$

$$10 < nl < [P0 \times 100 / (\text{最大值 } Px \times 1.3)] - 10 \quad (19)$$

上述四项约束旨在控制误差空间，避免后续人工神经网络训练出现过拟合现象——这种现象会导致价格轻易突破网格上下限，从而错失套利机会，同时确保参数始终处于合理范围内。

3.3.2. 解码方案

根据第3.3.1小节，网络交易模型的构建必须由总投资 $F0$ 、初始价格 $P0$ 、网格上限 Gul 、网格下限 Gll 以及网格总数 n 来设定。在本研究中， $F0$ 和 $P0$ 是控制变量，因此SSO需要求解的参数为 Gul 、 Gll 和 n 。在柔性网格中，网格总数 n 可划分为上层网格数量 nu 和下层网格数量 nl 。

溶液范围可参考下表1。

表1. 网络交易参数的上下限

使用范围	参数	可变上界	变量下限
实验1	网格上限 Gul	$P_0 \times 130\%$	$P_0 \times 105\%$
	网格下限 Gll	$P_0 \times 95\%$	$P_0 \times 70\%$
实验2	网格上限 Gul	$P_0 \times 150\%$	$P_0 \times 105\%$
	网格下限 Gll	$P_0 \times 95\%$	$P_0 \times 50\%$
常用	上网格数 nu	$[P_0 \times 100 / (\text{最大} P_x \times 1.3)] - 10$	10
	下网格数 nl	$[P_0 \times 100 / (\text{最大} P_x \times 1.3)] - 10$	10

本研究中的解编码请参考下图6，其中 $x1$ 、 $x2$ 、 $x3$ 和 $x4$ 分别设置为网格上限 Gul 、网格下限 Gll 、上网格数量 nu 和下网格数量 nl 。




图6. 编码溶液的结构

例如，当 $X = (150, 100, 10, 30)$ 时，表示网格上限为150，网格下限为100，上网格数为10，下网格数为30，网格总数为40。

3.3.3. 参数设置与更新机制范围

本研究采用SSO算法求解所研究问题，其中 ρ 为服从 $[0, 1]$ 区间均匀分布的随机数，问题解会根据该随机数进行动态更新。

$$t+1$$

当 ρ 介于 $[0, C_g)$ 之间时，变量 $x_{i,j}$ 将被全局最优解 gj 所替代，该解是当前所有解中性能最优的；当 ρ 介于 $[C_g, C_p)$ 之间时，该变量将被区域 pi, j 中的最优解所替代，该解是该变量在过往迭代中获得的最优解；当

$$t$$

当处于 $[C_p, C_w)$ 区间时，保持上一代解 xi, j ；当处于 $[C_w, 1)$ 区间时，

被 x 所替代，该随机数在变量的上下限范围内生成。更新机制可参考等式(2)。

SSO 操作中使用的符号及定义如下表2所示。

表2. SSO 符号与定义

符号	定义
NVA	变量数量：本研究中的网格上限 G_{ul} 、网格下限 G_{ll} 及网格总数 n 。
N-乙酰-1-氨基-1-磺酸	溶液总数。
${}_tX_i$	$X_{TI} = (G_{uli}^t, G_{lli}^t, nti)$ 表示第 t 代中的第 i 个解，其中 $t=1,2, \dots, Ngen, ..i=1,2, \dots, Nsol$ 。
$\widehat{G}_{ul}^p, \widehat{G}_{ul}^g, \widehat{G}_{ll}^p, \widehat{G}_{ll}^g, \widehat{n}^p, \widehat{n}^g$	$pbest$ 和 $gbest$ 在更新过程中每个变量的
C_g, C_p, C_w	SSO 中用于确定更新值的三个关键参数可根据不同情况进行调整。
后鳃	$UB = (ub1, ub2, \dots, ubNvar)$ 是每个变量的上界，即 $x \leq ub_j$ 。
LB	$LB = (lb1, lb2, \dots, lbNvar)$ 是每个变量的下限，即 $x \geq lb_j$ 。

3.4. 训练ANN自动调整柔性网格参数

通过 SSO 获取不同市场条件下的最优网格配置后，将市场条件和计算得出的网格参数作为人工神经网络训练的问答数据。市场状况通过以下指标进行量化输入：期间最高价、期间最低价、平均市场价格、平均交易量、价格变动（初始价减去最终价）、交易量变动（初始量减去最终量）、价格标准差和交易量标准差。

人工神经网络（ANN）的输出结果包含构建网格交易模型所需的参数，具体包括网格上限、网格下限、上层网格数量及下层网格数量。其具体架构可参考下图7。




图7. 人工神经网络（ANN）架构

在神经网络训练过程中，人工神经网络（ANN）节点中的权重会通过损失函数计算的误差值持续自我调整，直至训练完成并收敛到误差最小的状态。随后，通过该训练完成的神经网络，输入近期市场状态和趋势数据即可生成网格交易模型的最优参数，从而自动构建适用于市场交易活动的灵活网格模型。

本研究采用两种神经网络进行训练：全连接神经网络（FNN）和长时记忆（LSTM）神经网络。后者近年来常用于时间序列预测，旨在观察并比较这两种网络在学习网格参数方面的表现。

4. 实验结果

本研究用于验证和比较的数据集是标准普尔500指数（S&P500）、纳斯达克综合指数、道琼斯工业平均指数（DJIA）、欧洲斯托克50指数和上证综合指数，共计五个大型指数，时间跨度为2011年至2022年。

4.1. 固定参数下柔性网格性能的验证

首先，基于相同的网格数量和上下限，将柔性网格的性能与等距网格和等比例网格进行比较。结果可参见表3-5。网格数量通过等式（20）计算得出，以接近实际投资情况并确保资金使用的充分性。根据上下限条件，每个数据集被划分

将实验分为两组：第一组采用初始价格的1.3倍作为网格上限，0.7倍作为网格下限；第二组则采用初始价格的1.5倍作为网格上限，0.5倍作为网格下限。

从表3-5的结果可以看出，在5种不同综合指数10年波动下，采用相同网格参数进行交易时，灵活网格明显获得最佳ROI、累积财富和夏普比率，总体而言，灵活网格由于其交易结构，适当延迟了进出时机，获得了相对较高的ROI和夏普比率。

表3. 采用灵活网格、等距网格及等比例网格获得的ROI

网格类型	柔性网格	等距	等比例
S&P 500			
$(Gul, Gll) = (P_0 \times 1.3, P_0 \times 0.7)$	31.692 %	27.934 %	22.234 %
$(Gul, Gll) = (P_0 \times 1.5, P_0 \times 0.5)$	43.727 %	39.556 %	30.174 %
纳斯达克100指数			
$(Gul, Gll) = (P_0 \times 1.3, P_0 \times 0.7)$	53.795 %	49.261 %	40.369 %
$(Gul, Gll) = (P_0 \times 1.5, P_0 \times 0.5)$	71.888 %	66.024 %	51.180 %
道琼斯工业平均指数			
$(Gul, Gll) = (P_0 \times 1.3, P_0 \times 0.7)$	21.935 %	18.332 %	13.629 %
$(Gul, Gll) = (P_0 \times 1.5, P_0 \times 0.5)$	33.541 %	29.741 %	21.648 %
欧洲斯托克50指数			
$(Gul, Gll) = (P_0 \times 1.3, P_0 \times 0.7)$	0.601 %	-4.122 %	-7.284 %
$(Gul, Gll) = (P_0 \times 1.5, P_0 \times 0.5)$	17.499 %	12.520 %	7.087 %
上证综合指数			
$(Gul, Gll) = (P_0 \times 1.3, P_0 \times 0.7)$	-33.904 %	-38.944 %	-38.534 %
$(Gul, Gll) = (P_0 \times 1.5, P_0 \times 0.5)$	-12.955 %	-19.936 %	-18.290 %

表4. 通过灵活网格、等距网格和等比例网格获得的累积财富

网格类型	柔性网格	等距	等比例
S&P 500			
$(Gul, Gll) = (P_0 \times 1.3, P_0 \times 0.7)$	13169	12793	12223
$(Gul, Gll) = (P_0 \times 1.5, P_0 \times 0.5)$	14373	13956	13017
纳斯达克100指数			
$(Gul, Gll) = (P_0 \times 1.3, P_0 \times 0.7)$	15380	14926	14037
$(Gul, Gll) = (P_0 \times 1.5, P_0 \times 0.5)$	17189	16602	15118
道琼斯工业平均指数			
$(Gul, Gll) = (P_0 \times 1.3, P_0 \times 0.7)$	12194	11833	11363
$(Gul, Gll) = (P_0 \times 1.5, P_0 \times 0.5)$	13354	12974	12165
欧洲斯托克50指数			

$(Gul, Gll) = (P_0 \times 1.3, P_0 \times 0.7)$	10060	9588	9272
$(Gul, Gll) = (P_0 \times 1.5, P_0 \times 0.5)$	11750	11252	10709
上证综合指数			
$(Gul, Gll) = (P_0 \times 1.3, P_0 \times 0.7)$	6610	6106	6147
$(Gul, Gll) = (P_0 \times 1.5, P_0 \times 0.5)$	8705	8006	8171

表5. 通过柔性网格、等距网格和等比例网格获得的夏普比率

网格类型	柔性网格	等距	等比例
S&P 500			
$(Gul, Gll) = (P_0 \times 1.3, P_0 \times 0.7)$	0.118	0.103	0.092
$(Gul, Gll) = (P_0 \times 1.5, P_0 \times 0.5)$	0.160	0.145	0.137
纳斯达克100指数			
$(Gul, Gll) = (P_0 \times 1.3, P_0 \times 0.7)$	0.187	0.172	0.161
$(Gul, Gll) = (P_0 \times 1.5, P_0 \times 0.5)$	0.234	0.219	0.215
道琼斯工业平均指数			
$(Gul, Gll) = (P_0 \times 1.3, P_0 \times 0.7)$	0.079	0.065	0.054
$(Gul, Gll) = (P_0 \times 1.5, P_0 \times 0.5)$	0.119	0.105	0.095
欧洲斯托克50指数			
$(Gul, Gll) = (P_0 \times 1.3, P_0 \times 0.7)$	0.002	-0.011	-0.021
$(Gul, Gll) = (P_0 \times 1.5, P_0 \times 0.5)$	0.046	0.033	0.023
上证综合指数			
$(Gul, Gll) = (P_0 \times 1.3, P_0 \times 0.7)$	-0.082	-0.095	-0.106
$(Gul, Gll) = (P_0 \times 1.5, P_0 \times 0.5)$	-0.030	-0.047	-0.053

4.2. SSO 参数设定

然后，数据集的一部分被用于为所有后续实验选择合适的 SSO 参数。在第一组实验中， C_g 、 C_p 、 C_w 的配置如表6所示。其含义是将随机数 p 的范围按7:1:1:1的比例划分为四部分，并将比例为7的部分分配给

$t+1$

$gbest$ 、 $pbest$ 、 $x_{i,j}$ 以及实验中依次出现的新解，用于检测何种类型的解具有

对生产更高质量解决方案具有更关键的影响。

表6. 不同参数组合下的最佳与最差解决方案（实验1）

(C_g, C_p, C_w)	最大尺度解	ROI（最大值）	ROI（最小值）
(0.7,0.8,0.9)	最佳估计	69.74%	66.83%
(0.1,0.8,0.9)	最佳性能	69.62%	67.18%

(0.1,0.2,0.9)	$\mathbf{x}_{ij}^{t+1}$	69.69%	66.01%
(0.1,0.2,0.3)	新溶液	69.41%	66.69%

从表6中可以看出，当 $gbest$ 最大时，可以产生更高质量的解决方案，同时具有鲁棒性。因此，在最终参数配置中， $gbest$ 的概率被设置为最大值。

确定 $gbest$ 为最大概率后，将随机数 ρ 的范围按5:3:1:1分为四部分，其中取 $gbest$ 为解的概率设为最大值0.5，因为 $gbest$ 已在前一步骤中确定为关键因素。

$t+1$

为了生成高质量的解决方案，将概率0.3分配给 $pbest$ 、 $\mathbf{x}_{i,j}$ 以及一个新解决方案。根据实验结果，哪个解决方案是产生更好解决方案的第二个关键因素，结果如表7所示。

如表7所示，当新的随机解较大时，该方法能生成更高质量的解，同时保持稳健性。因此，新随机解的概率被设定为最终参数配置中次大值。

表7. 不同参数组合下的最佳与最差解决方案（实验2）

(C_g, C_p, C_w)	最大尺度解	ROI（最大值）	ROI（最小值）
(0.5,0.8,0.9)	最佳性能	69.77%	66.22%
(0.5,0.6,0.9)	$\mathbf{x}_{ij}^{t+1}$	69.77%	66.91%
(0.5,0.6,0.7)	新溶液	69.86%	67.83%

确定新随机解被设定为下一个最大概率后，随机数 ρ 的范围将按3:3:3:1的比例分为四部分。后续步骤与此类似。

$t+1$

前两步运算后，表8的计算结果如下。可以看出 $\mathbf{x}_{i,j}$ 与 $pbest$ 的数值变化不大。

因此，溶液质量的差异使得两种概率均被设定为最小值。

表8. 不同参数组合下的最佳与最差解决方案（实验3）

(C_g, C_p, C_w)	最大尺度解	ROI（最大值）	ROI（最小值）
(0.3,0.6,0.7)	最佳性能	69.85%	67.99%
(0.3,0.4,0.7)	$\mathbf{x}_{ij}^{t+1}$	69.90%	67.81%

4.3. 采用 SSO 选定参数验证柔性网格性能

设定 SSO 参数后，柔性网格、等距网格和等比例网格分别与 SSO 选定的参数相连接。通过 10 次运行、每次运行 20 代、每代 100 组解的方案进行求解。同时，针对不同风险水平的上下限，还进行了两组实验（与先前柔性网格架构验证相同）。结果详见表 9-11。

表 9. 采用柔性网格、等距网格及等比例网格与 SSO 参数获得的 ROI

网格类型	柔性网格	等距	等比例
S&P 500			
$(G_{ul}, G_{ll}) = (P_0 \times 1.3, P_0 \times 0.7)$	82.859 %	66.384 %	58.394 %
$(G_{ul}, G_{ll}) = (P_0 \times 1.5, P_0 \times 0.5)$	90.269 %	77.198 %	60.774 %
纳斯达克 100 指数			
$(G_{ul}, G_{ll}) = (P_0 \times 1.3, P_0 \times 0.7)$	111.649 %	66.384 %	82.662 %
$(G_{ul}, G_{ll}) = (P_0 \times 1.5, P_0 \times 0.5)$	127.268 %	110.179 %	86.208 %
道琼斯工业平均指数			
$(G_{ul}, G_{ll}) = (P_0 \times 1.3, P_0 \times 0.7)$	74.509 %	60.591 %	51.893 %
$(G_{ul}, G_{ll}) = (P_0 \times 1.5, P_0 \times 0.5)$	80.559 %	70.063 %	54.760 %
欧洲斯托克 50 指数			
$(G_{ul}, G_{ll}) = (P_0 \times 1.3, P_0 \times 0.7)$	77.220 %	56.650 %	48.365 %
$(G_{ul}, G_{ll}) = (P_0 \times 1.5, P_0 \times 0.5)$	88.844 %	72.293 %	55.856 %
上证综合指数			
$(G_{ul}, G_{ll}) = (P_0 \times 1.3, P_0 \times 0.7)$	58.389 %	39.178 %	33.363 %
$(G_{ul}, G_{ll}) = (P_0 \times 1.5, P_0 \times 0.5)$	80.954 %	58.934 %	43.639 %

表 10. 采用灵活网格、等距网格和等比例网格（含 SSO 参数）获得的累积财富

网格类型	柔性网格	等距	等比例
S&P 500			
$(G_{ul}, G_{ll}) = (P_0 \times 1.3, P_0 \times 0.7)$	18286	16638	15839
$(G_{ul}, G_{ll}) = (P_0 \times 1.5, P_0 \times 0.5)$	19027	17720	16077
纳斯达克 100 指数			
$(G_{ul}, G_{ll}) = (P_0 \times 1.3, P_0 \times 0.7)$	21165	16638	18266
$(G_{ul}, G_{ll}) = (P_0 \times 1.5, P_0 \times 0.5)$	22727	21018	18621
道琼斯工业平均指数			
$(G_{ul}, G_{ll}) = (P_0 \times 1.3, P_0 \times 0.7)$	17451	16059	15189
$(G_{ul}, G_{ll}) = (P_0 \times 1.5, P_0 \times 0.5)$	18056	17006	15476
欧洲斯托克 50 指数			

$(Gul, Gll) = (P_0 \times 1.3, P_0 \times 0.7)$	17722	15665	14837
$(Gul, Gll) = (P_0 \times 1.5, P_0 \times 0.5)$	18884	17229	15586
上证综合指数			
$(Gul, Gll) = (P_0 \times 1.3, P_0 \times 0.7)$	15839	13918	13336
$(Gul, Gll) = (P_0 \times 1.5, P_0 \times 0.5)$	18095	15893	14364

表11. 采用柔性网格、等距网格及等比例网格（含 SSO 参数）获得的夏普比率

网格类型	柔性网格	等距	等比例
S&P 500			
$(Gul, Gll) = (P_0 \times 1.3, P_0 \times 0.7)$	0.439	0.350	0.351
$(Gul, Gll) = (P_0 \times 1.5, P_0 \times 0.5)$	0.442	0.391	0.388
纳斯达克100指数			
$(Gul, Gll) = (P_0 \times 1.3, P_0 \times 0.7)$	0.498	0.350	0.437
$(Gul, Gll) = (P_0 \times 1.5, P_0 \times 0.5)$	0.524	0.464	0.462
道琼斯工业平均指数			
$(Gul, Gll) = (P_0 \times 1.3, P_0 \times 0.7)$	0.377	0.310	0.301
$(Gul, Gll) = (P_0 \times 1.5, P_0 \times 0.5)$	0.412	0.344	0.341
欧洲斯托克50指数			
$(Gul, Gll) = (P_0 \times 1.3, P_0 \times 0.7)$	0.300	0.219	0.211
$(Gul, Gll) = (P_0 \times 1.5, P_0 \times 0.5)$	0.331	0.265	0.257
上证综合指数			
$(Gul, Gll) = (P_0 \times 1.3, P_0 \times 0.7)$	0.189	0.134	0.131
$(Gul, Gll) = (P_0 \times 1.5, P_0 \times 0.5)$	0.220	0.179	0.172

从表9-11的结果可以看出，在应用 SSO 求解网格交易参数时，灵活网格在投资回报率（ROI）、累计财富和夏普比率方面仍优于等距网格和等比例网格。此外，对比 SSO 参数与固定参数版本的网格交易结果发现，投资回报率显著提升。综合投资回报率结果，灵活网格表现最佳，等距网格次之，等比例网格最差。

4.4. 训练ANN自动调整柔性网格参数

在验证 SSO 搜索交易参数的灵活网格系统表现优异后，该系统与 SSO 被用于记录各指数十年间的最优交易参数，从而每30天获取一组交易参数。为扩大后续训练与数据规模，将模型移动步长设定为5。针对各指标，共获取约500组参数数据用于人工神经网络（ANN）的训练与验证，其中前九年数据作为

训练集与去年的数据被用作验证集。

由于本研究训练集数据具有时间连续性，为避免影响模型训练结果，数据在 FNN 训练前需重新随机排序。在 LSTM 神经网络中，由于模型设计要求输入训练数据必须保持顺序，因此无需对训练数据进行随机重排序。

FNN 架构与 LSTM 神经网络经过多次实验验证，最终架构及超参数设置详见表12-14。

输入参数包括周期内最高价、周期内最低价、平均市场价格、平均交易量、价格变动、交易量变动、价格标准差、交易量标准差，共8个变量来描述市场行情，输出变量设置为网格交易的上界、下界、上网格数、下网格数。

隐藏层数设置为三层。优化器采用Adam优化器，这是近年来比较普遍的，收敛速度快，在搜索解方面有很好的性能，激励函数采用Sigmoid和ReLU，损失函数采用均方误差，这是回归问题中比较常用的。

表12. FNN 超参数与架构相关设置

物品	值集
输入变量数	8
隐藏层数	3
输出变量数	4
隐藏层节点数	500
优化器	土坝
激发函数	Sigmoid
损失函数	均方误差
世代数	300
批量大小	40

表13. LSTM 神经网络超参数与架构相关设置

物品	值集
输入变量数	8
隐藏层数	3
输出变量数	4
隐藏层节点数	256, 128, 64
优化器	土坝
激发函数	雷欧
损失函数	均方误差
世代数	300
批量大小	32

在完成上述神经网络训练集后，训练和比较结果如表14-15所示。从表14中等式（20）所示的均方误差结果来看：除纳斯达克100指数网格的上下限外，LSTM 的均方误差更小。其他指数中的四个输出变量均方误差也更小，FNN 在其他指数中四个输出变量的均方误差表现更佳。

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (20)$$

表14. FNN 与 LSTM 模型均方误差比较

神经网络类型	模糊神经网络	激光扫描跟踪法
S&P 500		
网格上限 <i>古尔</i>	129510	186366
网格下界 <i>Gll</i>	59787	108622
上网格数 <i>nu</i>	207	252
下网格数 <i>nl</i>	308	442
纳斯达克100指数		
网格上限 <i>古尔</i>	4725772	518181
网格下界 <i>Gll</i>	1681699	1162381
上网格数 <i>nu</i>	133	296
下网格数 <i>nl</i>	246	568
道琼斯工业平均指数		
网格上限 <i>古尔</i>	6016533	24446812
网格下界 <i>Gll</i>	2011354	19594848
上网格数 <i>nu</i>	164	237
下网格数 <i>nl</i>	319	402
欧洲斯托克50指数		
网格上限 <i>Gul</i>	105024	334456
网格下界 <i>Gll</i>	33988	106422
上网格数 <i>nu</i>	132	202
下网格数 <i>nl</i>	199	290
上证综合指数		
网格上限 <i>古尔</i>	65199	92869
网格下界 <i>Gll</i>	33604	26189
上网格数 <i>nu</i>	85	280
下网格数 <i>nl</i>	214	459

如表15所示，两个模型的决定系数（R平方）是衡量回归模型拟合度的指标，也可解释为模型的解释程度，其计算基于等式（21）。

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}} = \frac{\sum_{i=1} (y_i - f_i)^2}{\sum_{i=1} (y_i - \bar{y})^2} \quad (21)$$

表15显示，除纳斯达克100指数外，FNN 在多数情况下对四个输出变量的拟合效果更优。

表15. FNN 与 LSTM 模型的决定系数比较

神经网络类型	模糊神经网络	激光扫描跟踪法
S&P 500		90.490%
网格上限 <i>古尔</i>	97.410%	90.490%
网格下界 <i>Gll</i>	99.586%	97.240%
上网格数 <i>nu</i>	94.972%	99.469%
下网格数 <i>nl</i>	99.392%	94.892%
纳斯达克100指数		
网格上限 <i>古尔</i>	96.415%	98.075%
网格下界 <i>Gll</i>	97.088%	99.915%
上网格数 <i>nu</i>	94.942%	99.635%
下网格数 <i>nl</i>	94.737%	98.019%
道琼斯工业平均指数		
网格上限 <i>古尔</i>	97.704%	95.970%
网格下界 <i>Gll</i>	99.771%	93.429%
上网格数 <i>nu</i>	99.855%	93.685%
下网格数 <i>nl</i>	99.559%	91.285%
欧洲斯托克50指数		
网格上限 <i>古尔</i>	96.183%	94.392%
网格下界 <i>Gll</i>	99.324%	98.063%
上网格数 <i>nu</i>	99.297%	96.858%
下网格数 <i>nl</i>	98.405%	99.760%
上证综合指数		
网格上限 <i>古尔</i>	97.157%	96.577%
网格下界 <i>Gll</i>	96.749%	95.545%
上网格数 <i>nu</i>	93.165%	93.881%
下网格数 <i>nl</i>	99.661%	99.003%

此外，本研究采用以下四项指标评估模型性能：投资回报率（ROI）、最大回撤（MDD）、波动率和夏普比率。方法方面包括：首买末卖策略（BuyandSell, B&S）、首卖末买策略（SellandBuy, S&B）、网格交易系统机器人（GTSbot）[10]、一目均衡图（IK）[12]、基于全连接神经网络训练的柔性网格（FG- FNN）、基于 LSTM 训练的柔性网格（FG- LSTM）、等距网格、等比率网格及柔性网格，共计9种方法进行对比。

首先，ROI的计算公式可参考等式（22），这是投资科学中衡量量化投资绩效最常用的指标。投资收益与成本比率的计算通常以年化回报率表示为总回报率。交易成本（包括手续费）已包含在计算结果中。具体结果请参见表16。

$$\text{投资回报率} = (\text{净利润} - \text{投资成本}) \times 100\% \quad (22)$$

表16. ROI比较

	S&P	纳斯达克	道·琼斯指数	欧洲斯托克指数	Shanghai
B&S	14.392%	1.519%	9.880%	28.340%	-15.581%
S&B	-14.392%	-1.519%	-9.880%	-28.340%	15.581%
GTS机器人	6.408%	4.680%	6.594%	1.191%	-0.466%
IWOC	24.111%	23.171%	7.143%	32.087%	-18.758%
FG-FNN	11.520%	11.733%	8.849%	12.977%	-3.125%
前馈长短期记忆网络	4.639%	1.823%	2.940%	7.734%	-9.283%
等距	5.194%	-2.972%	3.480%	10.748%	-4.495%
等比例	4.536%	-3.625%	3.276%	10.764%	-4.892%
灵活的	5.589%	-1.895%	4.270%	11.477%	-4.309%

在投资回报率（ROI）方面，FNN 灵活网格在各指数中均位列前三。尤其值得一提的是，FNN 灵活网格在价格下行趋势中对整体亏损的控制能力最强。

其次，该比较指标为最大回撤值，即所有时期内收入急剧下降的金额，这是评估投资风险的指标之一。具体结果请参见表17。

表17. MDD 比较

	S&P	纳斯达克	道·琼斯指数	欧洲斯托克指数	Shanghai
B&S	7.960%	12.570%	7.290%	4.029%	8.529%
S&B	7.491%	10.370%	6.580%	7.313%	3.103%
GTS机器人	0.524%	5.335%	1.000%	0.510%	1.126%
IWOC	10.345%	12.421%	8.606%	5.467%	7.640%

FG-FNN	6.455%	5.596%	7.491%	2.034%	4.105%
--------	--------	--------	--------	--------	--------

前馈长短期记忆网络	1.580%	49.031%	4.809%	2.966%	3.551%
等距	5.252%	8.594%	4.078%	1.513%	4.074%
等比例	5.243%	10.096%	4.057%	1.529%	4.059%
灵活的	4.737%	8.780%	4.163%	4.144%	4.208%

就最大回撤而言，投资回报率较高的方法往往伴随相对较大的最大回撤，这印证了投资学中高风险高回报的理论。FNN 灵活网络在 MDD 中的表现存在双重原因：一是高投资回报率往往伴随着较高风险；二是各周期参数由神经网络计算得出，若某周期预测参数表现不佳，可能导致单周期出现大幅下跌。至于这种 MDD 条件是否可视为单一异常值，仍有待波动性数据验证。

在量化交易中，风险和模型稳定性通过其波动性进行评估。计算方法参考等式（23），结果如表18所示。

$$Vol = \sigma [return] \quad (23)$$

从表18可以看出，FNN 灵活网络在波动率指标上的表现位列各指标前三，即与其他方法相比，FNN灵活网络的表现非常稳定。可以推测，MDD 上的表现不佳可能是个别事件，在大多数情况下仍可视作稳健的投资模型。LSTM 灵活网络在标普和纳斯达克数据集中表现最佳，是一种风险较低且更稳健的投资模型。

表18. 挥发性比较

	S&P	纳斯达克	道·琼斯指数	欧洲斯托克指数	Shanghai
B&S	0.06126	0.07671	0.03568	0.06221	0.01840
S&B	0.06126	0.07671	0.03568	0.06221	0.01840
GTS机器人	0.01710	0.03589	0.01795	0.00267	0.00190
IWOC	0.07689	0.08398	0.04564	0.07337	0.03568
FG-FNN	0.01687	0.02076	0.02149	0.01730	0.01414
前馈长短期记忆网络	0.01672	0.01637	0.02203	0.01679	0.02030
等距	0.02450	0.03579	0.02129	0.01786	0.01590
等比例	0.02473	0.03629	0.02155	0.01828	0.01629
灵活的	0.02503	0.03665	0.02162	0.01862	0.01624

最后，就夏普比率而言，这是一种衡量模型性能的指标，用于计算投资回报与风险之间的比率。它也可以解释为每单位风险所能换取的回报。计算方法参考了等式（24），结果如表19所示。

$$Sharpe = return / \sigma [return] \quad (24)$$

表19. Sharpe比率比较

	S&P	纳斯达克	道·琼斯指数	欧洲斯托克指数	Shanghai
B&S	2.349	0.198	2.769	4.556	-8.466
S&B	-2.349	-0.198	-2.769	-4.556	8.466
GTS机器人	3.748	1.304	3.673	4.466	-2.446
IWOC	3.136	2.759	1.565	4.373	-5.258
FG-FNN	6.828	5.651	4.119	7.499	-2.210
前馈长短期记忆网络	2.774	1.114	1.335	4.606	-4.573
等距	2.120	-0.830	1.634	6.017	-2.827
等比例	1.834	-0.999	1.520	5.887	-3.004
灵活的	2.233	-0.517	1.975	6.165	-2.653

从表19可以看出，FNN灵活网络的夏普比率在四个指标中表现最优。在市场下跌时，除卖空操作外，其夏普比率也最高。由此可见，FNN灵活网络能为每单位风险带来最高回报。

5. 结论

除提出新型网格交易架构外，本研究有效提升了原模型的投资回报率，改善了过早入市和过早离场的弊端，并运用SSO算法和人工神经网络（ANN）辅助网格交易参数选择，使模型具备市场适应能力。

在模型性能方面，采用涵盖美国、欧洲和中国的五大主要市场指数作为验证数据。FNN灵活网格在夏普比率上表现优异，具有出色的投资回报率和模型稳健性，能有效平衡风险与收益。

本研究证明，结合人工智能技术的量化交易方法能够突破传统网格交易模型的局限，适应各种快速变化的市场环境。未来有望通过更多相关扩展研究，使网格交易模型在参数调整过程中更精准地模拟人类决策，甚至超越人类判断，消除人类冲动和市场情绪，从而做出理性交易决策，获得更优的投资收益。

致谢

本研究部分由中华民国国家科学技术委员会（MOST 107-2221-E-007-072-MY3、MOST 110-2221-E-007-107-MY3、MOST 109-2221-E-424-002及MOST 110-2511-H-130-002）资助。本文曾以临时提交形式提交至arXiv，仅作参考用途且未提供版权信息。

参考文献

- [1] J. IOSCO, 《技术变革对市场完整性和效率影响引发的监管问题》, 咨询报告, 2011年。
- [2] F.艾伦、J.麦克安德鲁斯、P.斯特拉汉合著的《电子金融: 导论》发表于《金融服务研究杂志》2002年第22卷第1期, 页码5-27。
- [3] 沙赫罗基先生, 《电子金融: 现状、创新、资源与未来挑战》, 《管理金融》, 2008年。
- [4] A.M. 图灵, 《计算机与智能》, 载于《解析图灵测试》, 斯普林格出版社(2009年), 第23-65页。
- [5] Hutson M. 研究人员如何教会人工智能像孩子一样学习, 《科学》10卷, 2018年。
- [6] M. Minsky, S. A. Papert, 《感知机: 计算几何导论》, 麻省理工学院出版社, 2017年。
- [7] Silver, D. 等, 利用深度神经网络与树搜索技术精通围棋。《自然》529 (7587) (2016) 484-489。
- [8] I.奥尔德里奇, 《高频交易: 算法策略与交易系统的实用指南》, John Wiley & Sons出版社, 第604页, 2013年。
- [9] 赖Z.R.、杨P.Y.、方L.、吴X.提出的《基于加权价格相对追踪的自动投资组合优化系统》发表于《IEEE系统、人与控制论汇刊: 系统》2018年第50卷第11期, 页码4349-4361。
- [10] F. Rundo、F. Trenta、A. L. d. Stallo、S. Battiato, 《网格交易系统机器人(gtssbot): 一种新型外汇市场交易数学算法》, 《应用科学》9(9) (2019) 1796。
- [11] Q.温、Z.杨、Y.宋、P.贾, 基于箱理论与SVM算法的自动股票决策支持系统, Expert Systems with Applications 37(2) (2010) 1015-1022。
- [12] S. Deng, A. Sakurai, 《基于 Ichimoku Kinkohyo 支撑/阻力位的短期外汇交易》, IEEE《Information Science、电子与 Electrical Engineering》2014年 International Conference, 2014年。
- [13] A. Ye、V. L. R. Chinthalapati、A. Sergueeva、E. Tsang, 《利用高频数据方向性变化制定可持续交易策略》, 2017年IEEE国际大数据会议, 2017年。
- [14] A. DuPoly, The Expert4x、No stop、Hedged、Grid Trading System以及The Hedged、MultiCurrency、Forex Trading System, 2008年。

- [15] W.C.叶、S.C.魏，《基于Grid Bank的可靠网格计算服务的经济性资源分配》，《未来计算机系统》28(7)（2012）989-1002。
- [16] S.C. Wei, W.C. Yeh, 可靠且经济高效的网格资源分配决策模型

基于Grid Bank的应用程序, 未来世代计算机系统 77 (2017) 12-28。

- [17] W.C. Yeh, 一种用于串联系统多级冗余分配问题的两阶段离散粒子群优化算法, *Expert Systems with Applications* **36**(5) (2009) 9192-9200.
- [18] W.C. Yeh, 《基于新型群优化算法的甲状腺数据分类规则挖掘》, 《信息科学》 197卷 (2012年) 65-76页。
- [19] W.C.叶、W.W.张、Y.Y.钟, 《一种基于离散粒子群优化与统计方法的乳腺癌模式挖掘新混合方法》, 《专家系统与应用》 36(4) (2009) 8204-8211。
- [20] W.C. Yeh, Z. Liu, Y.C. Yang, S.Y. Tan, 基于改进简化群优化的多层规划求解双渠道供应链定价策略问题, *Technologies* 2022 (10) (2022) doi.org/10.3390/technologies10030073
- [21] H.C.S. Lin, C.L. Huang, W.C. Yeh, 一种基于简化群优化的可靠性冗余分配问题的可信度模糊约束模型, *应用科学* 11 (10765) (2021) doi: 10.3390/app112210765
- [22] 叶文昌、赖鹏杰、李文昌、M.C.Chuang, 并行机调度以最小化模糊处理时间和学习效应下的总工期, *信息科学* 269 (2014) 142-158.
- [23] W.C. Yeh, W. Zhu, S.Y. Tan, G.G. Wang, Y.H. Yeh, 新型通用主动可靠性冗余分配问题及算法, *可靠性工程与系统安全*, 218 (2021) 108167.
- [24] W.C. Yeh, S.Y. Tan, 时变连续速度函数下异构车队车辆路径规划的简化群优化算法, *电子学*, 2021 (10) (2021) doi:10.3390/electronics10151775
- [25] C. Bae、W.C. Yeh、N. Wahid、Y.Y. Chung、Y. Liu提出了一种新的简化群优化算法 (SSO) 采用Exchange本地搜索方案, 《国际创新计算、信息与控制期刊》第8卷第6期 (2012年) 4391-4406页。
- [26] 叶文才、苏永志、高晓、胡春峰、王杰、黄春立, 《简化群优化算法在双目标主动可靠性冗余分配问题中的应用》, 《应用软计算》 106卷 (2021年) 107321页。
- [27] 王先生、叶W.C.、朱T.C.、张X.、黄C.L.、杨J., 基于IFR与SSO算法混合方法求解无线智能传感器网络不确定性下的多目标模糊优化, *Energies* 11(9) (2018) 2385。
- [28] W.C.是的, 具有学习效应的简化群优化在拆卸排序问题中的应用, *计算机与运筹学* 39 (9) (2012) 2168-2177。
- [29] W.C. Yeh, 一种新型边界群优化方法用于可靠性冗余分配问题, *可靠性工程与系统安全* 192 (2019) 106060.
- [30] W.C. Yeh, 《基于正交简化群优化的混合组件串并联冗余分配问题研究》, 《知识系统》 64卷 (2014年) 1-12页。
- [31] W. Zhu、W.C. Yeh、L. Cao、Z. Zhu、D. Chen、J. Chen、A. Li、Y. Lin、更快的进化

- 基于iSSO的卷积神经网络在医学图像病灶识别中的应用，《基础与临床药理学与毒理学》124卷（2019年）329-329页。
- [32] 叶文才、林鹏、黄崇林，《简化群优化法在太阳能电池模型参数估计中的应用》，IET 可再生能源发电11(8)（2017）1166-1173。
- [33] P. Lin、S. Cheng、W.C. Yeh、Z. Chen、L. Wu，基于改进简化群优化算法的太阳能电池模型参数提取，《太阳能》144卷（2017年）594-603页。
- [34] W.C. Yeh，《基于简化无参数群优化算法的人工神经网络训练及其在时间序列预测中的应用》，《IEEE神经网络与学习系统汇刊》2013年第24卷第4期，第661-665页。
- [35] 黄伟、赖克凯、中森勇、王思、余立，《金融与经济预测中的神经网络》，《国际信息技术与决策》第6卷第1期（2007年）第113-140页。
- [36] S. Qi, K. Jin, B. Li, Y. Qian, 基于神经网络的互联网金融探索，计算与应用数学杂志 369（2020）112630.
- [37] S.西亚米-纳米尼、A.S.纳明，《预测经济学与金融时间序列：ARIMA 与LST》arXiv预印本 arXiv:1803.06386,2018.
- [38] J. Cao, Z. Li, J. Li, 基于CEEMDAN和LST的金融时间序列预测模型，物理A: 统计力学及其应用 519（2019）127-139.
- [39] N.杰加迪什，《证券收益率可预测性的证据》，《金融杂志》第45卷第3期（1990年）第881-898页。
- [40] N.杰加迪什，《股票价格均值回归的季节性特征：来自美国和英国的证据》，《金融杂志》第46卷第4期（1991年）1427-1444页。
- [41] B.李、P.赵、S.C.H.何、V.戈帕尔克里希南，PAMR：被动攻击性均值回归策略在投资组合选择中的应用，机器学习87(2)（2012）221-258。
- [42] W.S. McCulloch, W. Pitts, 神经活动内在思想的逻辑演算，《数学生物物理学通报》5(4)（1943）115-133.
- [43] F. 罗森布拉特，《感知器：大脑信息存储与组织的概率模型》，《心理评论》65(6)（1958）386。
- [44] P. Werbos，《超越回归：行为科学中的预测与分析新工具》，哈佛大学博士论文，1974年。
- [45] D.E. Rumelhart, G.E. Hinton, R.J. Williams, 通过反向传播误差学习表征. Nature 323（6088）（1986）533-536.
- [46] S.Ruder，《梯度下降优化算法概述》，arXiv预印本 arXiv:1609.04747,2016年。

- [47] J.M. Poterba, L.H. Summers, 股价均值回归：证据与启示, 《金融经济学杂志》22(1) (1988) 27-59。
- [48] B. Hurst、Y.H. Ooi、L.H. Pedersen, 《趋势跟踪投资百年实证研究》, 《投资组合管理杂志》第44卷第1期(2017年), 第15-29页。